MKB 一次提问的完整流程（实现逻辑）

下面按时间顺序说明「点发送之后发生了什么」。对应界面上的四个阶段。

阶段 A：问题分析（understand）

目的：弄清你到底在问什么，以及要不要重新查文献。

1. 前端把「当前问题 + 对话上下文摘要」发给后端 `/api/ask`
2. 大模型返回结构化判断（JSON），主要包括：
    - **关系**：追问 / 换题 / 改写
    - **问题类型**：疗效、预防、诊断、预后、病因、机制、其他
    - **独立问题**（中文）：即使不看历史也能看懂的完整问句（例如把「那女性呢」补成「……在女性患者中的……」）
    - **检索式**（英文，1～3 条）：给 PubMed 用的查询串

改写类问题到此结束检索分支，直接进入「改写上一回答」。

否则继续：

3. 系统按问题类型**自动追加一条「研究设计过滤器」**（例如疗效问题更偏向系统综述、Meta、指南、RCT），提高高证据等级文献的占比。这条过滤器是系统拼的，不要求用户会写。

阶段 B：循证检索（search）

目的：从 PubMed 拉回一批相关文献元数据与摘要。

1. 用多条检索式分别搜索，合并去重，目标大约 **100 篇**（可配置）
2. 拉取每篇的标题、摘要、期刊、年份、作者、PMID、PMCID、DOI、文献类型等
3. 前端立刻收到文献列表，可先浏览「搜到了什么」

若一篇都搜不到，流程终止并提示换问法。

阶段 C：证据整理（fulltext + passages）

目的：尽量用「全文里真正相关的段落」作答，而不是整篇摘要硬塞给模型。

1. **选全文候选**：在有 PMCID（通常意味着可能有 PMC 开放全文）的文章里，按相关度优先，并预留少量名额给高证据等级文献（如 Meta、RCT），最多约 **10 篇**（可配置）
2. **拉取开放获取全文**（PMC）；去掉参考文献、致谢、脚注等噪音，并尽量剥离正文里的角标引用数字，避免干扰语义匹配
3. **排除撤稿**文献，不参与证据池
4. **切块（Chunk）**：把全文/摘要切成约千字一段、段间略有重叠的小块——像把厚书拆成索引卡片
5. **向量检索（RAG）**：
    - 用向量模型把「本轮独立问题」和每一段文字都变成数字向量
    - 算相似度，选出最相关的约 **12 段**（可配置）
    - 限制同一篇文献贡献太多段落，避免答案被一篇文「霸屏」

兜底策略（保证系统尽量仍能答）：

情况	回退
没有开放全文	用摘要参与切块与检索
向量检索失败	直接用一批摘要拼给模型
既无全文也无摘要	仅依据标题等信息，并提示证据有限

阶段 D：生成回答（answer）

目的：基于本轮证据写出可读、可溯源的中文回答。

1. 大模型收到严格提示词：只能依据给定段落；关键结论标 `[PMID:…]`；证据冲突要说局限；末尾声明不能替代诊疗
2. **流式输出**：前端逐字/逐词显示
3. 更新「对话备忘」（见下一节），供下一轮追问用
4. 生成最多 3 条追问建议
5. 发送结束事件；前端可继续做标题中译等辅助请求

整条链路用 **SSE（服务器推送事件）** 把状态、文献、段落、正文片段推到浏览器，因此你能看到「正在检索…」「正在获取全文…」等进度。